Universidad de Ciencias Aplicadas (UPC)

ALDIMI-PREDICT

Machine Learning - 1ACC0057

Profesor: Robert Ernesto Zubieta Cardenas

Integrantes

Apellidos y Nombres	Código	Roles
Abanto Davila, Alvaro Jair Moises	U202313540	ML Engineer
Ballon Villar, Diego Eduardo	U201520327	MLOps / Developer
Chipoco Mejia Jorge Piero Jesus	U202210236	Data Architect
Vasquez Trujillano, Edson Fabrizio	U202316342	Data Scientist

Índice

1. Resumen Ejecutivo..... 3
1.1. Descripción de la problemática abordada por ALDIMI..... 3
2. Marco Metodológico: CRISP-DM Aplicado..... 4
2.1. Business Understanding..... 4
2.1.1. Objetivos..... 4
2.1.2. Dataset..... 4
2.1.3. Definición de las variables objetivo..... 5
2.1.4. Criterios de éxito técnico..... 6
2.2. Data Understanding & Exploratory Data Analysis (EDA)..... 6
2.2.1. Análisis de los conjunto de datos..... 6
2.2.2. Análisis de correlaciones y distribuciones..... 9
2.2.3. Identificación de valores atípicos y datos faltantes..... 15
3. Anexos..... 19
3.1. Enlace al repositorio (GitHub/GitLab)..... 19
3.2. Diccionario de datos inicial..... 20

1. Resumen Ejecutivo

1.1. Descripción de la problemática abordada por ALDIMI

Desde su constitución en 2004, la asociación ALDIMI ha consolidado un modelo de atención integral gratuito dirigido a menores con patologías oncológicas en situación de vulnerabilidad extrema. La operatividad de la organización se centra en mitigar las barreras de acceso a la salud para familias provenientes de regiones descentralizadas, proporcionando soporte logístico, alimentario y emocional en la capital.

Sin embargo, el tránsito hacia el modelo "ALDIMI 2.0", el cual proyecta duplicar la capacidad instalada para albergar de 50 a 100 familias, ha evidenciado una crisis de escalabilidad derivada de la dependencia de procesos analógicos que resultan insuficientes ante el incremento de la demanda operativa. La problemática central se divide en tres ejes críticos:

- **Incapacidad de priorizar:** La organización carece de un sistema para la clasificación de pacientes oncológicos según la gravedad de su caso. Esta limitación impide que el equipo actúe de manera proactiva ante pacientes con mayor probabilidad de recaída o deterioro agudo, incrementando la vulnerabilidad de los menores albergados ante crisis de salud.
- **Demanda de alimentos:** La organización recibe donaciones constantemente; sin embargo, no posee un sistema que regule el stock de alimentos. Esto puede causar desabastecimiento, lo cual impedirá brindar la adecuada alimentación a los pacientes.
- **Merma de Recursos:** Existe una problemática aguda de desperdicio y merma de alimentos que caducan por un mal manejo de la rotación, impidiendo que los recursos perecederos lleguen a los beneficiarios antes de su vencimiento.

Ante este escenario, surge el proyecto ALDIMI-Predict. La intervención mediante Machine Learning es vital para garantizar el Derecho a la Salud (ODS 3) y Reducir las Desigualdades (ODS 10). El proyecto se enfoca en el desarrollo de un motor analítico centralizado que procesa datos para generar alertas preventivas en dos frentes:

- Predicción de Demanda y Logística: Optimización del inventario para asegurar el abastecimiento de alimentos.
- Clasificación de Riesgo de Salud: Clasificación de pacientes con bajo, medio y alto riesgo de complicaciones clínicas.

2. Marco Metodológico: CRISP-DM Aplicado

2.1. Business Understanding

2.1.1. Objetivos

Para abordar la problemática, se han definido dos objetivos para cada frente:

- Desarrollar modelos de series temporales para predecir el stock crítico de alimentos con horizontes de 7 y 14 días, garantizando el abastecimiento oportuno y reduciendo la merma con el estado del alimento.
- Implementar algoritmo de clasificación supervisada para identificar tempranamente a pacientes oncológicos con alta probabilidad de complicaciones clínicas, permitiendo intervenciones preventivas basadas en datos.

2.1.2. Dataset

- Predicción de Demanda y Logística:

Optimización del inventario para asegurar el abastecimiento de medicinas o alimentos a 7 o 14 días mediante el uso del dataset real FreshRetailNet-50K.

  - Especificaciones del Dataset: Cuenta con 4.85 millones de registros horarios y 50,000 series temporales de 863 productos perecederos (SKUs).
  - Valor Logístico: Incluye anotaciones de quiebre de stock (stockouts), lo que permite al motor de ALDIMI recuperar la "demanda latente" y evitar desabastecimientos críticos.
  - Variables de Contexto: El modelo integrará datos reales de clima (precipitación), temperatura y humedad para ajustar el abastecimiento.
  - Acceso: https://huggingface.co/datasets/Dingdong-Inc/FreshRetailNet-50K

- Clasificación de Riesgo de Salud:

Este dataset constituye el motor para la identificación temprana de complicaciones oncológicas basándose en un volumen masivo de datos clínicos.

  - Modelos de Clasificación: Permite el desarrollo de algoritmos para clasificar el "Nivel de Prioridad de Atención" (Bajo/Medio/Alto) basado en variables de agudeza y riesgo.

- Variables de Estilo de Vida: Contiene información sobre la exposición al aire contaminado, el uso de alcohol y la tendencia a fumar de los pacientes.
- Detalle Clínico: Proporciona datos sobre el tipo de cáncer, la etapa del diagnóstico (0 a IV), la puntuación de severidad y los años de supervivencia tras el diagnóstico.Volumen: Incluye microdatos de 50,000 pacientes reales diagnosticados globalmente entre los años 2015 y 2024.
- Acceso: https://www.kaggle.com/datasets/zahidmughal2343/global-cancer-patients-2015-2024

2.1.3. Definición de las variables objetivo

Para que el motor analítico de ALDIMI-Predict sea funcional, se han definido variables objetivo específicas para cada frente.

- Predicción de Demanda y Logística:

En este frente, el objetivo es anticipar la demanda de suministros (alimentos mapeados como product_id) para optimizar el inventario perecedero.

- Variable Objetivo (y):
  - demand7: Proyecta la cantidad acumulada necesaria para cubrir la demanda en los 7 días posteriores a la fecha ingresada (dt), calculada como: $demand7_t = \sum_{i=1}^{7} saleamount_{t+i}$.
  - demand14: Proyecta la cantidad acumulada necesaria para cubrir la demanda en los 14 días posteriores a la fecha ingresada (dt), calculada como: $demand14_t = \sum_{i=1}^{14} saleamount_{t+i}$.
  - perece: Proyecta el estado del alimento que perece con mayor frecuencia.
- Naturaleza: Variable continua (basada en el campo float64 de sale_amount).
- Justificación: Predecir el volumen de stock mínimo necesario que permita a la administración gestionar donaciones y compras antes de llegar al desabastecimiento. Error máximo: Se establece un error máximo permitido

del 8%, dado que el impacto de la ruptura de stock en suministros críticos es alto.

- Clasificación de Riesgo de Salud

El objetivo es identificar de forma automatizada el nivel de prioridad de atención del paciente en base a la severidad de su caso para priorizar recursos de monitoreo y tratamiento.

  - Variable Objetivo (y):
    - Prioridad: Una variable categórica que clasifica la prioridad de atención mediante las clases: Bajo, Medio y Alto.
  - Naturaleza: Variable categórica.
  - Justificación: Esta variable sintetiza indicadores clínicos relacionados al cáncer diagnosticado e indicadores sociales relacionados al estilo de vida del paciente para clasificar la prioridad de la atención médica.
  - Error máximo: Consideramos un error máximo permitido del 15% puesto que es fundamental brindar atención a los casos más severos.

2.1.4. Criterios de éxito técnico

- Motor de Predicción de Demanda y Logística

El éxito técnico en este eje se mide por la capacidad de evitar el desabastecimiento sin generar sobrestock de productos perecederos.

Precisión de Pronóstico (Error Máximo): El modelo debe alcanzar un **MAPE (Mean Absolute Percentage Error) < 8%** para los horizontes de 7 y 14 días. Este límite es vital para mitigar el impacto de falta de medicinas críticas

- Motor de Clasificación de Riesgo de Salud

En salud oncológica, el éxito técnico se prioriza en la Sensibilidad (Recall) para no omitir a ningún paciente en riesgo.

Discriminación Clínica (ROC-AUC): El modelo de clasificación supervisada debe alcanzar un **ROC-AUC > 0.85** (tomando como referencia modelos de mortalidad oncológica en MIMIC-IV). Un valor cercano a 1.0 indicaría una capacidad excepcional para distinguir entre niveles de prioridad.

2.2. Data Understanding & Exploratory Data Analysis (EDA)

2.2.1. Análisis de los conjunto de datos

- Predicción de Demanda y Logística:

DESCRIPCIÓN GENERAL DEL DATASET

Dimensiones: 100,000 filas × 26 columnas

Ciudades únicas: 1

Tiendas únicas: 13

Productos únicos: 273

Fechas únicas: 90

Desde: 2024-03-28

Hasta: 2024-06-25

```
TIPOS DE DATOS POR COLUMNA:
--------------------------------------------------
                              Tipo  Valores únicos  Nulos  % Nulos
city_id                     int64               1      0      0.0
store_id                    int64              13      0      0.0
management_group_id         int64               7      0      0.0
first_category_id           int64              25      0      0.0
second_category_id          int64              64      0      0.0
third_category_id           int64             150      0      0.0
product_id                  int64             273      0      0.0
dt                  datetime64[ns]              90      0      0.0
sale_amount               float64             327      0      0.0
hours_sale                 object  N/A (sequence)      0      0.0
stock_hour6_22_cnt          int32              17      0      0.0
hours_stock_status         object  N/A (sequence)      0      0.0
discount                  float64             855      0      0.0
holiday_flag                int32               2      0      0.0
activity_flag               int32               2      0      0.0
precpt                    float64            1030      0      0.0
avg_temperature           float64             566      0      0.0
avg_humidity              float64             697      0      0.0
avg_wind_level            float64             118      0      0.0
day_of_week                 int32               7      0      0.0
month                       int32               4      0      0.0
week                        int64              14      0      0.0
is_weekend                  int64               2      0      0.0
stockout_rate             float64              17      0      0.0
has_stockout                int64               2      0      0.0
has_discount                int64               2      0      0.0
```

<u>Estadísticas descriptivas:</u>

	count	mean	std	min	25%	50%	75%	max	skewness	kurtosis
sale_amount	100000.0	1.0320	1.1872	0.0000	0.4000	0.7000	1.2000	22.9000	3.9996	26.9663
stock_hour6_22_cnt	100000.0	3.1504	4.4585	0.0000	0.0000	0.0000	6.0000	16.0000	1.2936	0.6129
discount	100000.0	0.9146	0.1136	0.3580	0.8510	0.9880	1.0000	1.0000	-1.3606	1.2622
holiday_flag	100000.0	0.3445	0.4752	0.0000	0.0000	0.0000	1.0000	1.0000	0.6546	-1.5714
activity_flag	100000.0	0.3990	0.4897	0.0000	0.0000	0.0000	1.0000	1.0000	0.4123	-1.8300
precpt	100000.0	3.1430	2.9828	0.2112	1.4168	2.0875	3.2152	15.5666	1.9814	3.4363
avg_temperature	100000.0	21.5411	3.5161	14.3200	18.3900	21.7900	24.0600	28.7200	0.0073	-1.0510
avg_humidity	100000.0	74.2154	5.2160	62.8000	70.2600	74.4500	77.5000	87.0500	-0.0047	-0.5013
avg_wind_level	100000.0	1.6236	0.2492	1.0400	1.4600	1.6200	1.7700	2.6100	0.4073	0.3210

```
MEDIANAS DE COLUMNAS NUMÉRICAS:
--------------------------------
sale_amount            0.7000
stock_hour6_22_cnt     0.0000
discount               0.9880
holiday_flag           0.0000
activity_flag          0.0000
precpt                 2.0875
avg_temperature       21.7900
avg_humidity          74.4500
avg_wind_level         1.6200
```

- Clasificación de Riesgo de Salud

DESCRIPCIÓN GENERAL DEL DATASET

Dimensiones: 50,000 filas × 15 columnas

Pacientes únicos: 50,000

Rango de edades: 20 a 90 años

Desde: 2015

Hasta: 2024

```
TIPOS DE DATOS POR COLUMNA:
--------------------------------------------------
                         Tipo  Valores únicos  Nulos  % Nulos
Patient_ID             object           50000      0      0.0
Age                     int64              70      0      0.0
Gender                 object               3      0      0.0
Country_Region         object              10      0      0.0
Year                    int64              10      0      0.0
Genetic_Risk          float64             101      0      0.0
Air_Pollution         float64             101      0      0.0
Alcohol_Use           float64             101      0      0.0
Smoking               float64             101      0      0.0
Obesity_Level         float64             101      0      0.0
Cancer_Type            object               8      0      0.0
Cancer_Stage           object               5      0      0.0
Treatment_Cost_USD    float64           49861      0      0.0
Survival_Years        float64             101      0      0.0
Target_Severity_Score float64             744      0      0.0
```

Estadísticas descriptivas:

	count	mean	std	min	25%	50%	75%	max	mediana
Age	50000.0	54.4215	20.2245	20.00	37.000	54.00	72.00	89.00	54.00
Genetic_Risk	50000.0	5.0017	2.8858	0.00	2.500	5.00	7.50	10.00	5.00
Air_Pollution	50000.0	5.0101	2.8884	0.00	2.500	5.00	7.50	10.00	5.00
Alcohol_Use	50000.0	5.0109	2.8888	0.00	2.500	5.00	7.50	10.00	5.00
Smoking	50000.0	4.9898	2.8816	0.00	2.500	5.00	7.50	10.00	5.00
Obesity_Level	50000.0	4.9912	2.8945	0.00	2.500	5.00	7.50	10.00	5.00
Treatment_Cost_USD	50000.0	52467.2982	27363.2294	5000.05	28686.225	52474.31	76232.72	99999.84	52474.31
Survival_Years	50000.0	5.0065	2.8833	0.00	2.500	5.00	7.50	10.00	5.00
Target_Severity_Score	50000.0	4.9512	1.1997	0.90	4.120	4.95	5.78	9.16	4.95

2.2.2. Análisis de correlaciones y distribuciones

- Predicción de Demanda y Logística:

Análisis de Distribución:

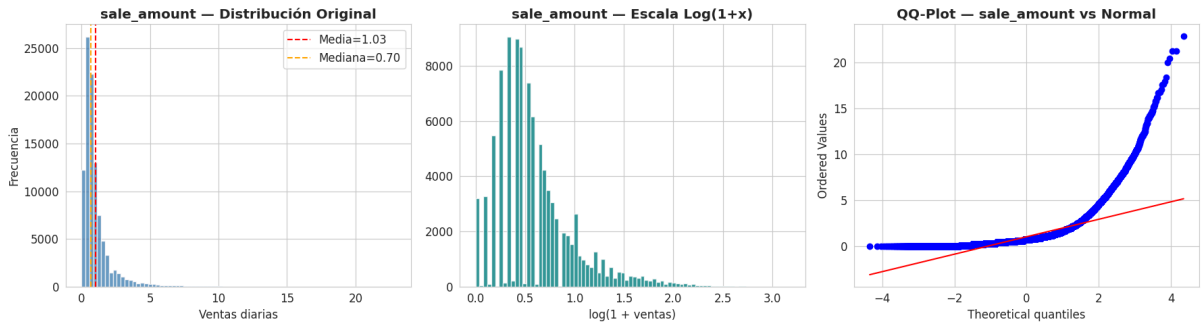

sale_amount no sigue una distribución normal. Los valores estadísticos confirman una distribución con sesgo positivo muy elevado (skewness = 4,0) y colas extremadamente pesadas (kurtosis = 26,97), lo que descarta el uso de modelos de regresión lineal ordinaria sin transformaciones previas. Se recomienda utilizar esta transformación tanto para la variable objetivo como para el análisis de residuales en los modelos de predicción. El QQ-plot confirma la existencia de un exceso de observaciones cercanas a cero (posibles días de desabastecimiento o demanda nula) y de observaciones en la cola superior muy por encima de lo esperado bajo normalidad. El porcentaje de registros con sale_amount igual a 0 debe cuantificarse con precisión, dado que podría indicar días de stock-out completo más que ausencia real de demanda. Estos registros requieren tratamiento diferenciado en la fase de modelado (modelos inflados en cero o modelos de demanda censurada).

<u>Distribución de variables binarias:</u>

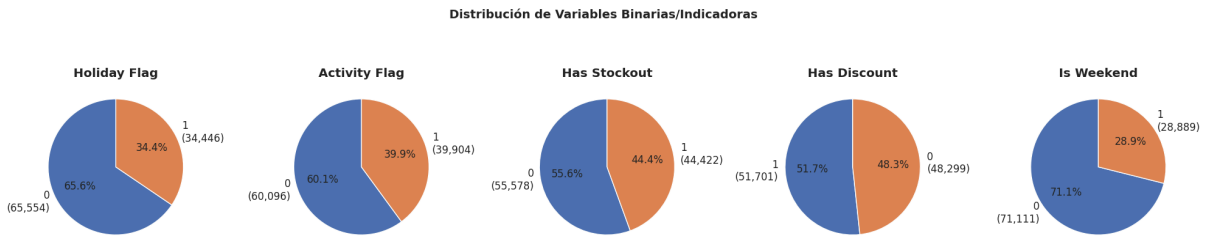

El análisis de las variables categóricas revela que presenta una tasa de desabastecimiento del 44.4% (44,422 casos), cifra significativamente superior al 20% orgánico del dataset original, lo que indica una sobrerrepresentación de eventos de stock-out que debe considerarse al generalizar conclusiones. Por su parte, la proporción de días festivos es del 34.4% (34,446 registros), una cifra elevada para el periodo de 90 días analizado que justifica el uso de la variable festiva como covariable predictiva, mientras que el indicador de fin de semana (28.9%) se mantiene consistente con la estructura temporal del calendario. En cuanto a la dinámica comercial, aunque el 51.7% de los registros cuenta con algún descuento, la mediana de 0.988 sugiere que la mayoría son marginales, destacando además que la actividad comercial activa (39.9%) guarda una estrecha relación estructural con los periodos festivos, validada por una correlación de Pearson de -0.77 entre el descuento y la bandera de actividad.

<u>Analisis de correlacion:</u>

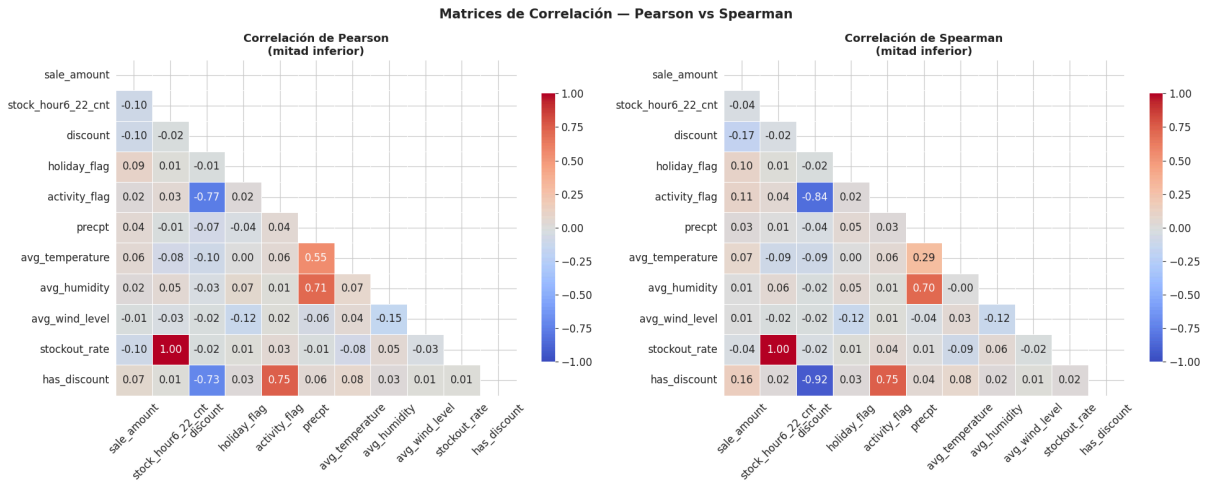

Las correlaciones entre sale_amount y el resto de las variables son bajas en ambas matrices (máximo 0,10 en valor absoluto con holiday_flag), lo que indica que las ventas no tienen una relación lineal o monótona fuerte con ninguna variable individual. Esto apunta a que los modelos predictivos requerirán interacciones entre variables o enfoques no lineales. La alta correlación entre discount y activity_flag (-0,77) genera multicolinealidad potencial en modelos de regresión. Antes del modelado, se recomienda evaluar la inclusión de solo una de estas variables, o crear una variable combinada que capture el efecto conjunto. La correlación entre precpt y avg_humidity (0,71) también puede generar multicolinealidad. Dado que avg_humidity tiene mayor correlación con otras variables de interés, podría ser más informativa como covariable. Las correlaciones de Spearman generalmente superan o igualan a las de Pearson en valor absoluto, lo que sugiere que las relaciones en el dataset son frecuentemente monótonas y no lineales. Este hallazgo favorece el uso de modelos basados en rangos o transformaciones de potencia. La correlación negativa entre stock_hour6_22_cnt y sale_amount (-0,10 Pearson, -0,04 Spearman) es baja pero con signo esperado: a más horas de desabastecimiento, menores ventas registradas. La baja magnitud se debe precisamente a la censura: muchos registros con alta demanda real aparecen con ventas bajas por estar en stock-out."

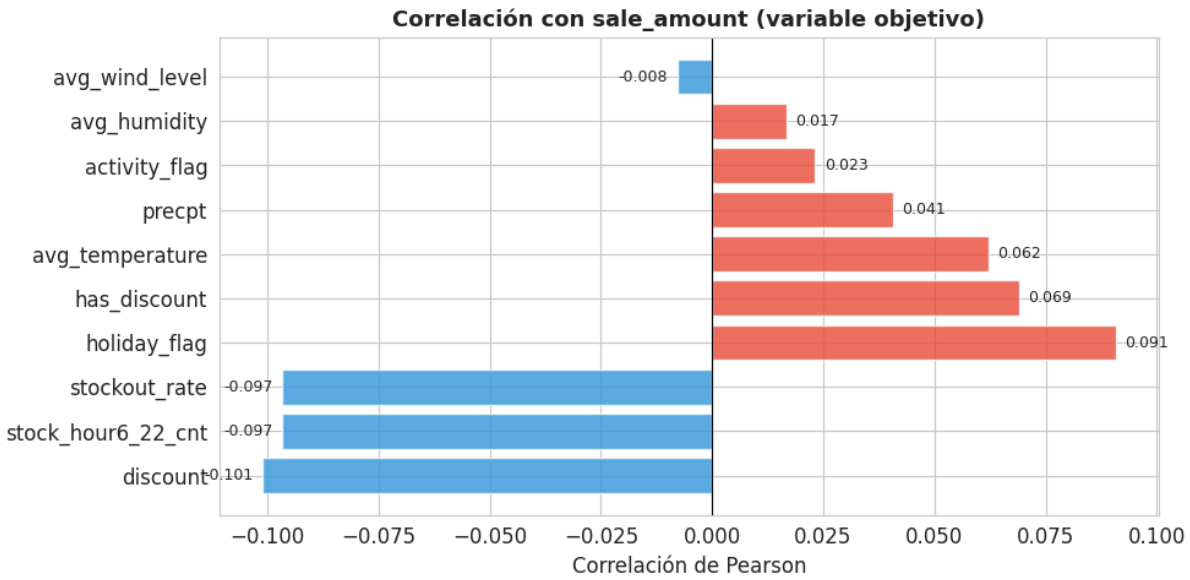

Ninguna variable individual presenta una correlación de Pearson superior a 0,10 en valor absoluto con sale_amount. Esto confirma que las ventas de productos frescos son un fenómeno complejo determinado por la interacción de múltiples factores más que por el efecto aislado de cualquier predictor individual. El signo negativo de discount (-0,101) es contraintuitivo: significa que días con mayor descuento están asociados a menores ventas observadas. Sin embargo, esto se debe a la colinealidad del descuento con el stock-out y los días de promoción masiva, donde la logística puede verse comprometida. El efecto causal real del descuento sobre la demanda latente puede ser positivo. La correlación positiva de holiday_flag (0,091) indica que los días festivos se asocian a ventas ligeramente superiores, lo que es coherente con el comportamiento de compra acelerada de productos frescos antes de los dias festivos. La temperatura (0,062) tiene un efecto positivo sobre las ventas, coherente con la mayor demanda de frutas y verduras en épocas de calor. Este efecto, aunque modesto en correlación lineal, podría ser más pronunciado en modelos no lineales. El bajo valor de correlación no significa que las variables sean irrelevantes para el modelado: las relaciones no lineales, las interacciones entre variables y la naturaleza censurada de la variable objetivo hacen que los modelos de machine learning (gradient boosting, redes neuronales) puedan capturar efectos que la correlación lineal no detecta.

- Clasificación de Riesgo de Salud:

<u>Análisis de correlación</u>

Nuestra variable objetivo dentro del conjunto de datos es “Target_Severity_Score”. Se

observa que los factores de riesgo de mayor correlación con la variable objetivo son “Genetic_Risk” y “Smoking” con un puntaje de 0.48; seguidos por “Air_Pollution” y “Alcohol_Use” con puntajes de 0.37 y 0.36 respectivamente; y, finalmente, por “ Obesity_Level” con 0.25. En ese sentido, estos cinco factores presentan una relación moderada a baja con la severidad del cáncer del paciente; es decir, si un paciente muestra niveles altos en estos factores, es posible que la severidad de su caso sea también alta. Desde otra perspectiva, el impacto económico presenta una relación muy débil con la severidad del cáncer, lo cual nos indica que el costo del tratamiento no es proporcional a la severidad del caso. Esta observación es interesante ya que uno esperaría que los casos más graves requieren de más gastos durante el tratamiento; sin embargo, esta relación demuestra lo contrario. Finalmente, existe una correlación negativa del objetivo con “Survival_Years”, lo cual indica que cuanto más grave fue un caso de cáncer, menos años sobrevivió el paciente.

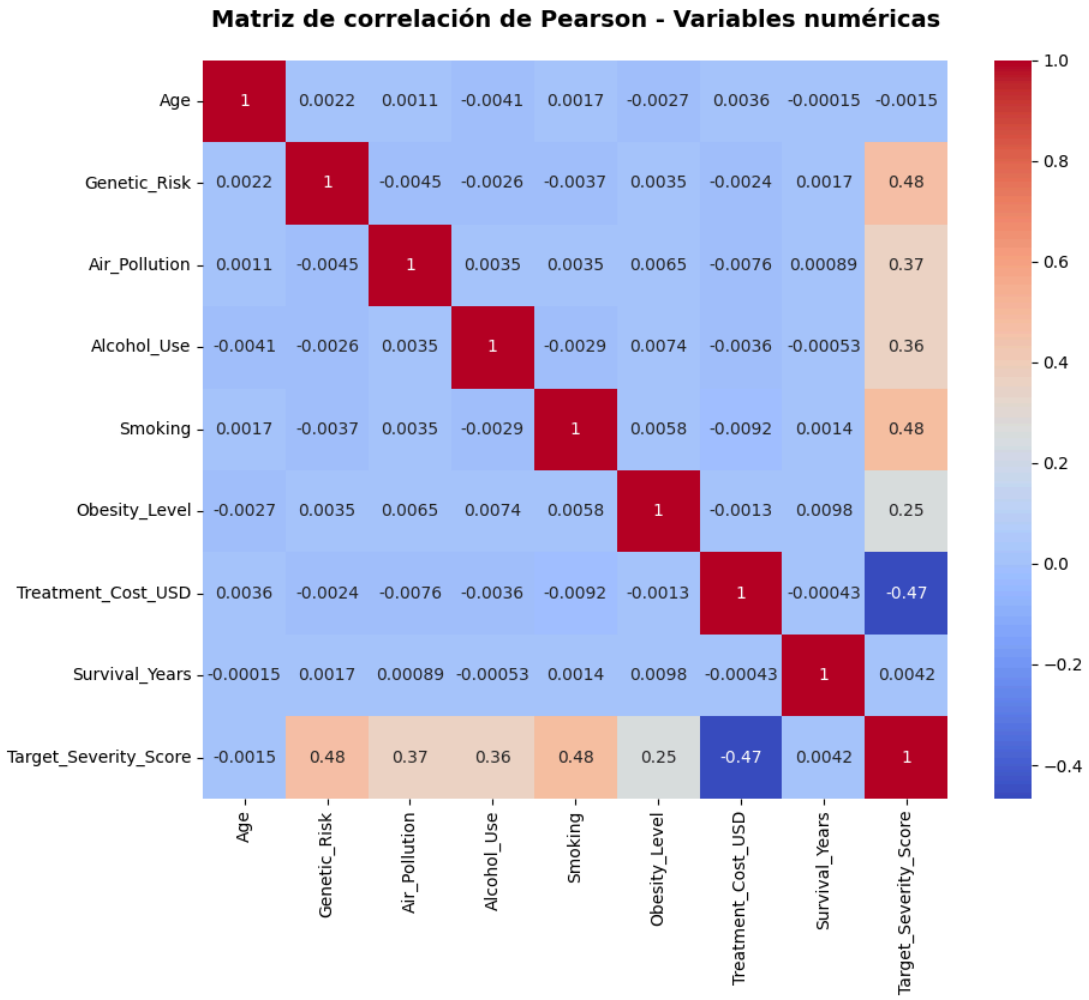

<u>Análisis de distribuciones</u>

La variable “Age” mantiene un rango de edades entre los 20 a 90 años. Se observa que la variable mantiene una frecuencia similar (no igual debido a la existencia de picos) a lo largo de su rango, lo cual indica que no existe un sesgo o grupo etario predominante. Las variables “Genetic_Risk”, “Air_pollution” , “Alcohol_Use”, “Smoking” y “Obesity_Level” siguen un sistema de puntaje del 0 al 10, el cual indica la gravedad de la característica del paciente que reflejan. Estas cinco variables siguen una distribución casi uniforme, es decir, no existe una concentración en niveles bajos ni en los altos. La variable “Treatment_Cost_USD” sigue una distribución uniforme. Los costos de tratamiento registrados a lo largo del conjunto de datos aparecen con una frecuencia casi igual según lo observado en su histograma. La variable “Survival_Years” mantiene un rango entre los 0 a 10 años de supervivencia. La frecuencia de sus registros indica que no hay sesgo entre casos de baja o alta supervivencia. Por último, entre las variables numéricas, la variable “Target_Severity_Score” posee una distribución normal. Se observa una concentración de resultados en el puntaje número 5 para esta variable.

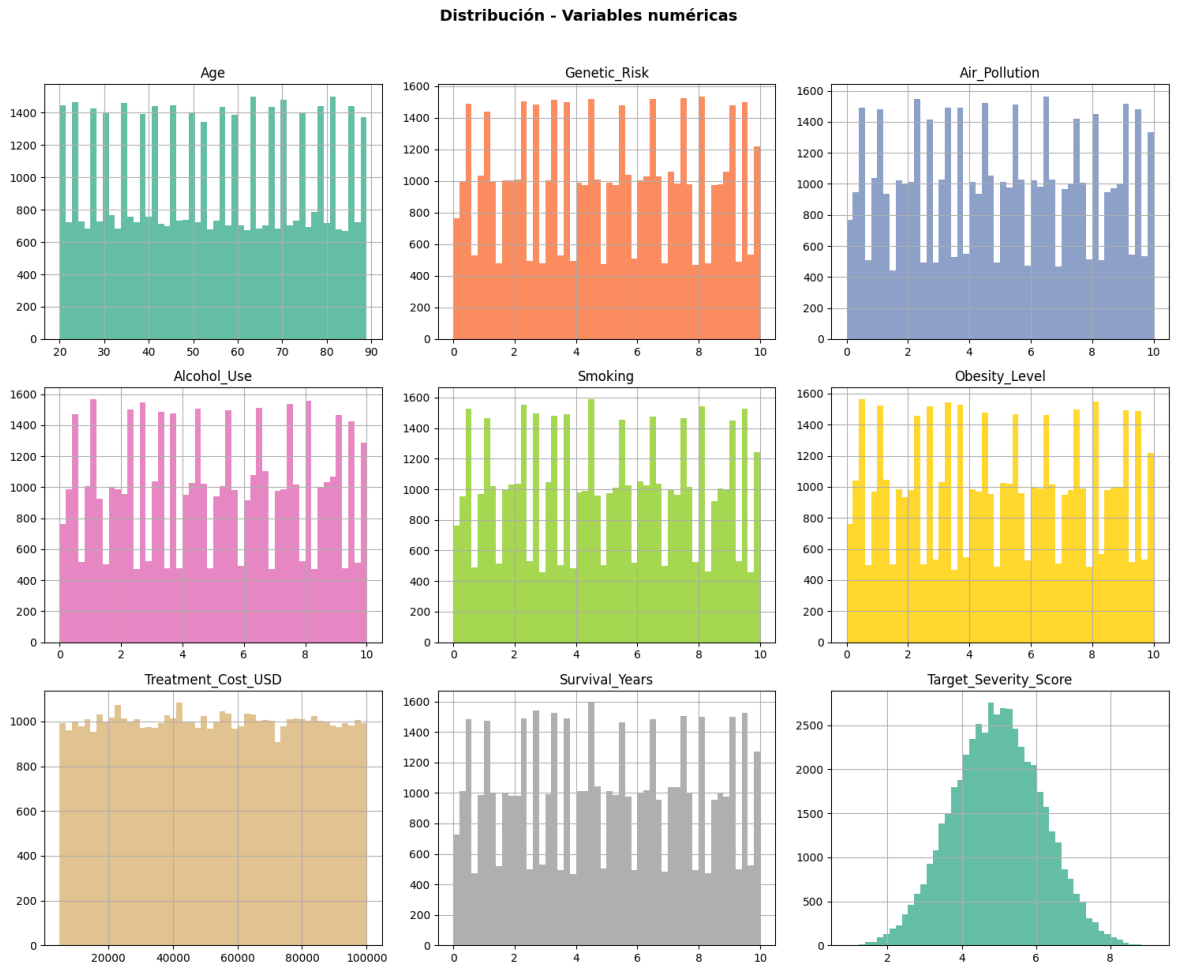

Desde otra perspectiva, realizando un análisis a la frecuencia de las variables categóricas, se observa que las variables “Gender”, “Year”, “Country_Region”, “Cancer_Type” y “Cancer_Stage” poseen frecuencias casi iguales entre todos sus registros. En ese sentido, el conjunto de datos no presenta sesgos o fueron tratados previamente a su publicación en línea.

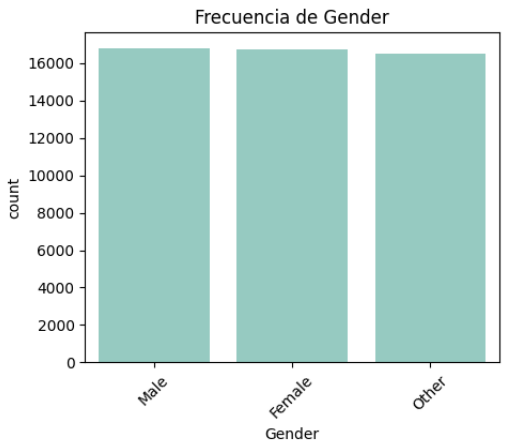

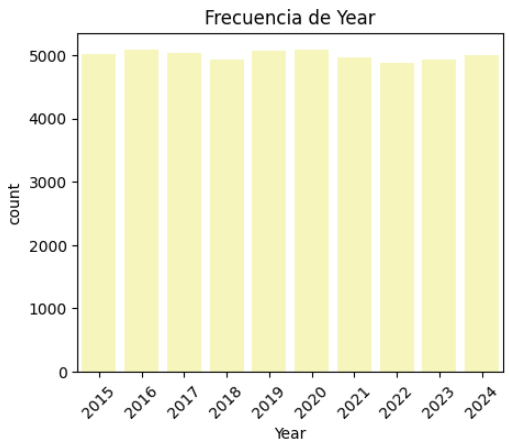

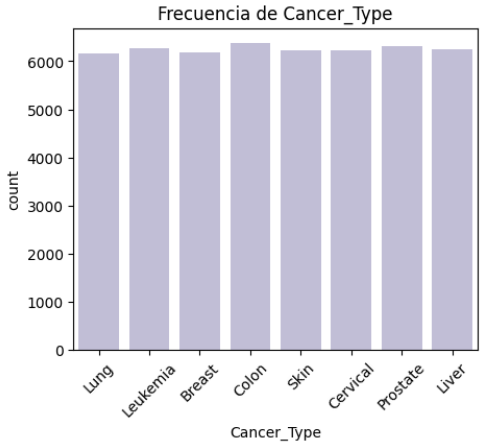

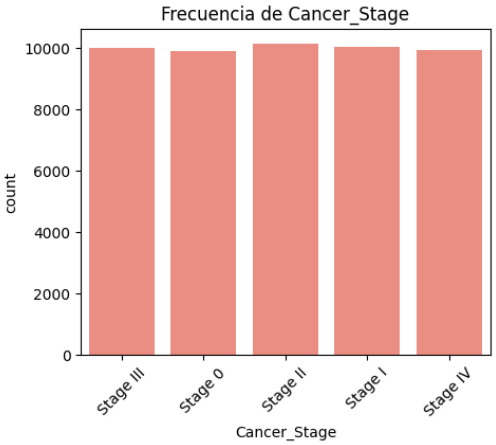

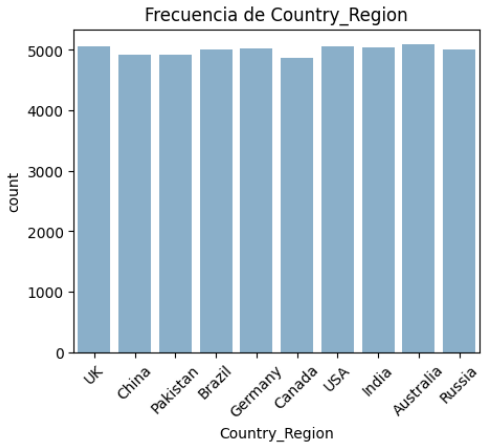

2.2.3. Identificación de valores atípicos y datos faltantes

- Predicción de Demanda y Logística:

<u>Valores nulo o faltantes:</u>

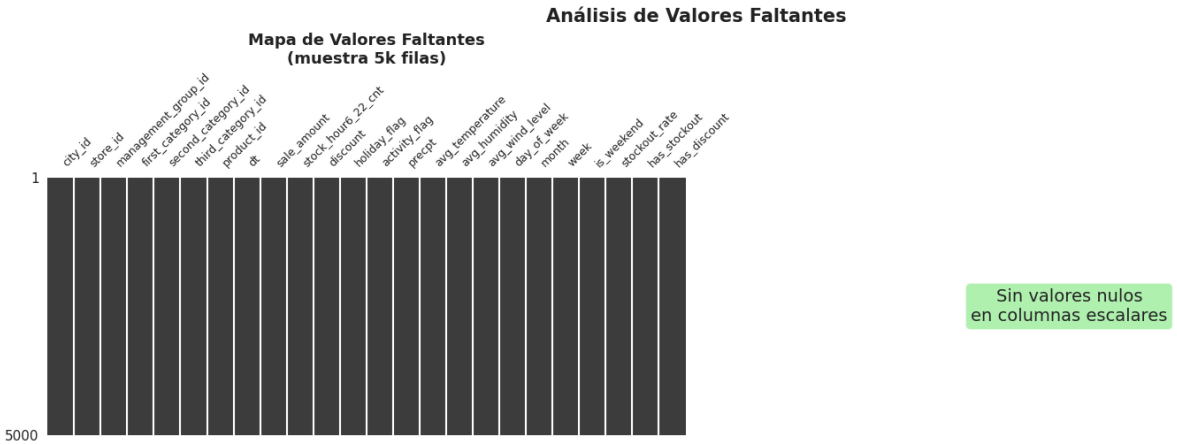

El dataset FreshRetailNet-50K no contiene valores nulos en ninguna de sus 26 columnas escalares analizadas, lo que implica que no se requiere ningún proceso de imputación previo al modelado.La completitud es total: los 100.000 registros de la muestra presentan datos válidos en todas las variables numéricas, de identificación y de contexto temporal. Esta característica es poco común en datasets de retail de gran escala y representa una ventaja significativa para la calidad del análisis: las estadísticas descriptivas y las correlaciones calculadas reflejan la distribución real de los datos sin sesgo introducido por la sustitución de valores faltantes. Las únicas columnas de tipo secuencia (hours_sale y hours_stock_status) no son escalares y, por diseño del dataset, contienen arrays de 24 posiciones por fila; su integridad estructural también fue verificada.

Columna	Min	Max	IQR_Lower	IQR_Upper	Outliers_IQR	Outliers_IQR_%	Outliers_Z>3	Outliers_Z_%
sale_amount	0.0000	22.9000	-0.800	2.400	7917	7.92	2313	2.31
stock_hour6_22_cnt	0.0000	16.0000	-9.000	15.000	2690	2.69	0	0.00
precpt	0.2112	15.5666	-1.281	5.913	14474	14.47	3371	3.37
avg_temperature	14.3200	28.7200	9.885	32.565	0	0.00	0	0.00
avg_humidity	62.8000	87.0500	59.400	88.360	0	0.00	0	0.00
avg_wind_level	1.0400	2.6100	0.995	2.235	1619	1.62	483	0.48
discount	0.3580	1.0000	0.628	1.224	3350	3.35	1393	1.39

<u>Reporte de Outliers:</u>

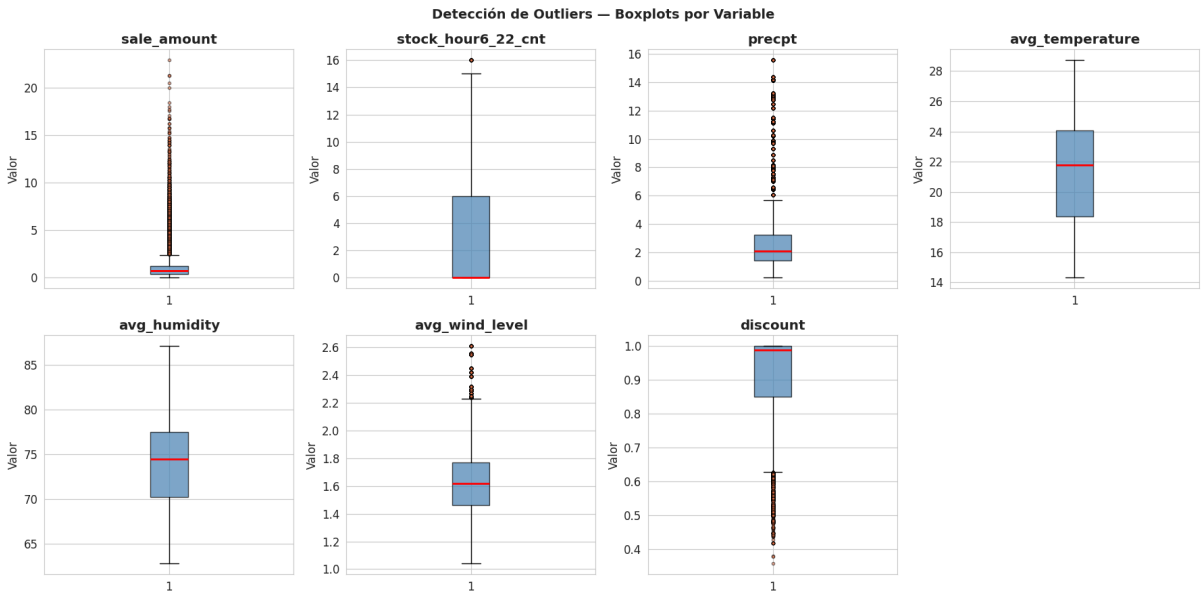

El panel de siete boxplots revela que la variable **sale_amount** posee la mayor densidad de valores atípicos positivos, con registros de hasta 22.9 unidades que representan picos de demanda real necesarios para el modelo. Por otro lado, **stock_hour6_22_cnt** presenta una mediana de cero, evidenciando que la mayoría de los registros no sufren desabastecimiento, aunque sus valores extremos de hasta 16 horas son informativos para estimar la demanda censurada. Mientras las variables climáticas como **avg_temperature**, **avg_humidity** y **avg_wind_level** muestran distribuciones compactas y estables acordes a la estacionalidad primavera-verano, la **precpt** (precipitación) está fuertemente sesgada a la derecha con eventos extremos de lluvia de hasta 15.6 mm. Finalmente, el **discount** exhibe una distribución bimodal inversa donde la mayoría de los registros están a precio completo (1.0), y los valores atípicos inferiores a 0.65 corresponden a eventos promocionales agresivos poco frecuentes que deben modelarse mediante categorías o umbrales.

- Clasificación de Riesgo de Salud

<u>Identificación de valores atípicos:</u>

Las variables "Genetic_Risk", "Air_Pollution", "Alcohol_Use", "Smoking" y "Obesity_Level", las cuales comparten un mismo rango de valores, no poseen valores atípicos. De la misma forma, las variables "Age", "Treatment_Cost_USD" y "Survival_Years" no presentan valores atípicos. Sin embargo, la variable objetivo “Target_Severity_Score” sí presenta valores atípicos según se observa en su diagrama boxplot.

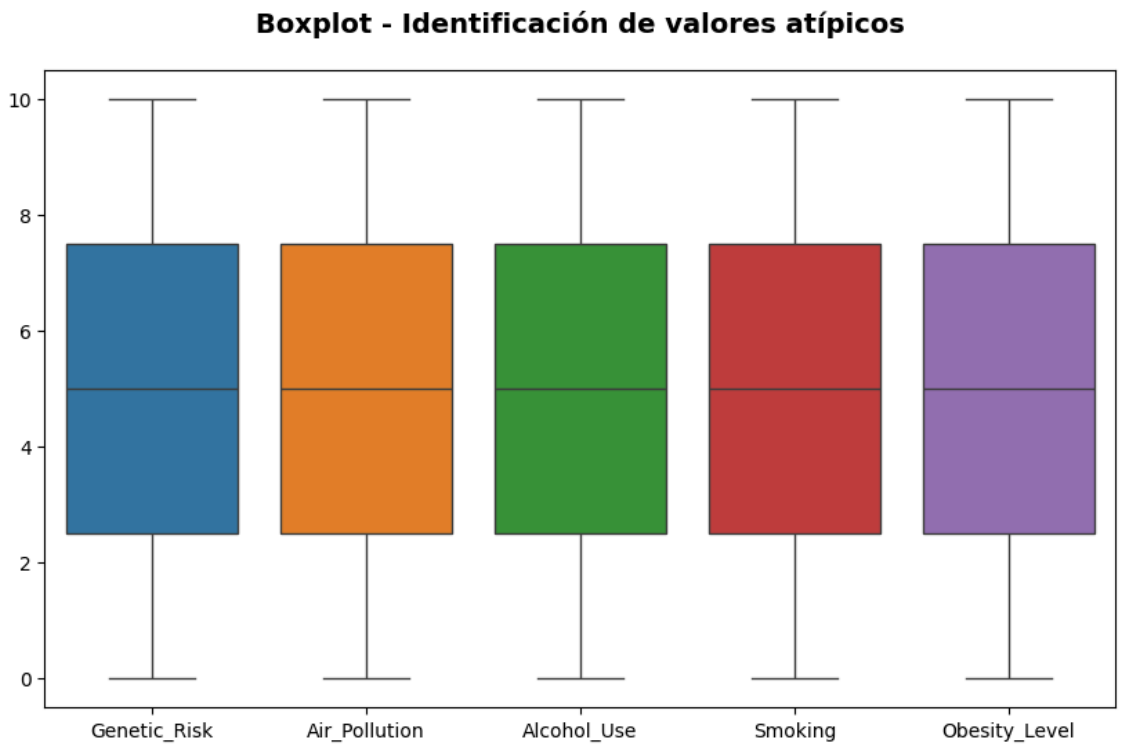
Boxplot - Identificación de valores atípicos
10
8
6
4
2
0
Genetic_Risk
Air_Pollution
Alcohol_Use
Smoking
Obesity_Level

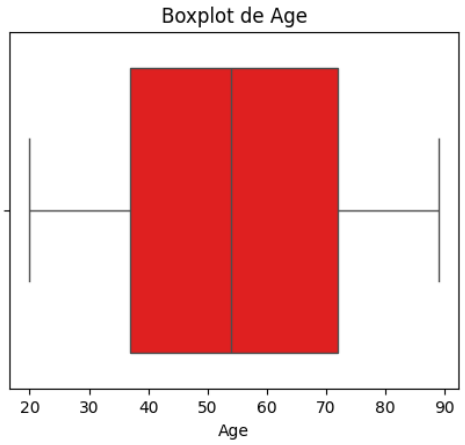
Boxplot de Age
20
30
40
50
60
70
80
90
Age

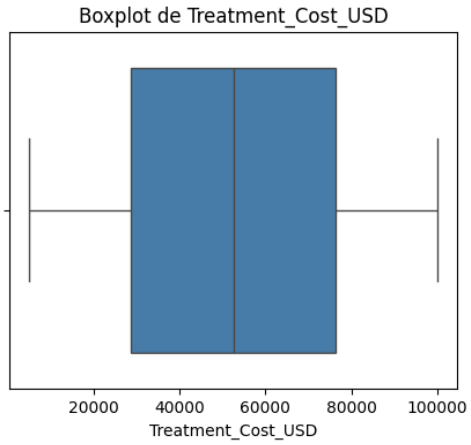
Boxplot de Treatment_Cost_USD
20000
40000
60000
80000
100000
Treatment_Cost_USD

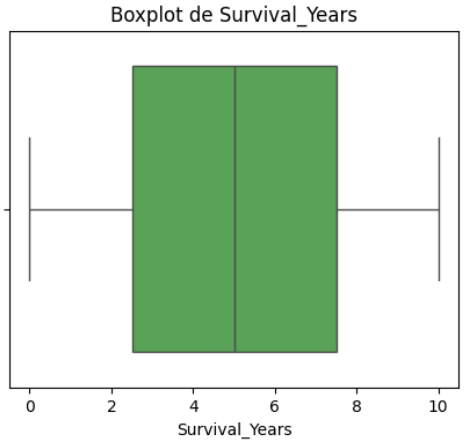
Boxplot de Survival_Years
0
2
4
6
8
10
Survival_Years

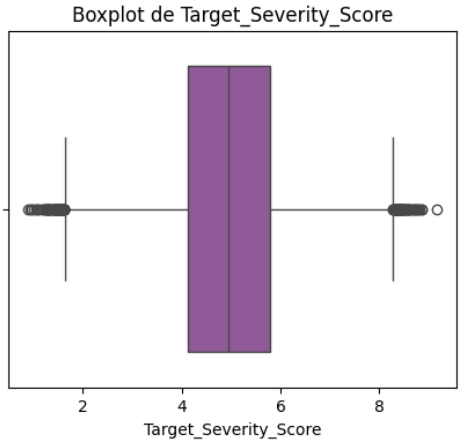
Boxplot de Target_Severity_Score
2
4
6
8
Target_Severity_Score

REPORTE DE OUTLIERS:

Columna	Min	Max	IQR_Lower	IQR_Upper	Outliers_IQR	Outliers_IQR_%
Target_Severity_Score	0.9	9.16	1.63	8.27	151	0.3

Se observaron 151 valores atípicos, considerando a IQR como el límite de detección.

Identificación de valores nulos:

Se revisó la cantidad de valores nulos. Se observa que ninguna columna posee estos valores. El conjunto de datos mantiene una data completa, permitiendo que no sea necesario realizar imputación. De esta forma, se evita posible pérdida de precisión en los modelos a desarrollar.

	Cantidad de nulos
Patient_ID	0
Age	0
Gender	0
Country_Region	0
Year	0
Genetic_Risk	0
Air_Pollution	0
Alcohol_Use	0
Smoking	0
Obesity_Level	0
Cancer_Type	0
Cancer_Stage	0
Treatment_Cost_USD	0
Survival_Years	0
Target_Severity_Score	0

3. Anexos

3.1. Enlace al repositorio (GitHub/GitLab)

https://github.com/Britzi0/MachineLearning_1ACC0057_2610_GRUPO3

3.2. Diccionario de datos inicial

- Predicción de Demanda y Logística:

  El conjunto de datos “FreshRetailNet-50K” contiene la siguiente información:

Campo	Tipo	Descripción
city_id	int64	El id de ciudad codificado
store_id	int64	El ID de la tienda codificado
management_group_id	int64	El id codificado del grupo de gestión
first_category_id	int64	El id de primera categoría codificado
second_category_id	int64	El id codificado de segunda categoría
third_category_id	int64	El id codificado de tercera categoría
product_id	int64	El id de producto codificado
td	Cuerda	La fecha
sale_amount	float64	El importe diario de las ventas tras la normalización global (multiplicado por un coeficiente específico)
hours_sale	Secuencia(float64)	El importe de las ventas por hora tras la normalización global (multiplicado por un coeficiente específico)
stock_hour6_22_cnt	int32	El número de horas agotadas entre las 6:00 y las 22:00
hours_stock_status	Secuencia(int32)	El estado de agotado por horas
Descuento	float64	El tipo de descuento (1,0 significa sin descuento, 0,9 significa 10% de descuento)
holiday_flag	int32	Indicador de festividades
activity_flag	int32	Indicador de actividad

Precipt	float64	La precipitación total
avg_temperature	float64	La temperatura media
avg_humidity	float64	La humedad media
avg_wind_level	float64	La fuerza media del viento

- Clasificación de Riesgo de Salud

  El conjunto de datos "global_cancer_patients_2015_2024" contiene la siguiente información:

Variable	Tipo de variable	Descripción
Patient_ID	Categórica	Identificador del paciente.
Age	Numérica	Edad del paciente. Rango descrito: 20 a 90 años.
Gender	Categórica	Género del paciente: Male, Female, Other
Country_Region	Categórica	País de origen.
Year	Numérica	Año del registro.
Genetic_Risk	Numérica	Presencia de genes mutantes que influyen en el desarrollo del cáncer.
Air_Pollution	Numérica	Exposición al aire contaminado.
Alcohol_Use	Numérica	Tendencia a la ingesta de alcohol.
Smoking	Numérica	Tendencia a fumar.
Obesity_Level	Numérica	Nivel de obesidad del paciente.
Cancer_Type	Categórica	Tipo de cáncer: Breast, Colon, etc.
Cancer_Stage	Categórica	Etapa del cáncer: Desde Stage 0 hasta Stage IV.
Treatment_Cost_USD	Numérica	Costo estimado del

		tratamiento del cáncer expresado en dólares americanos.
Survival_Years	Numérica	Años que el paciente sobrevivió desde el diagnóstico del cáncer.
Target_Severity_Score	Numérica	Puntaje calculado que representa la severidad del cáncer del paciente. Es una variable clave para clasificar la prioridad de atención de los pacientes.